

**Министерство науки и высшего образования  
Российской Федерации  
федеральное государственное автономное образовательное  
учреждение высшего образования  
«Национальный исследовательский университет ИТМО»  
(Университет ИТМО)**

**ОТЧЕТ  
ПО НАУЧНОЙ РАБОТЕ СТАЖИРОВКИ НОЛ ТЗ**

<b>Тема:</b>	<b>Применение сверточных нейронных сетей для оценки состояния капилляров по данным видеокapилляроскопии в условиях ограниченного объема обучающей выборки</b>
<b>ФИО стажёра:</b>	<b>Кудрявцев Алексей Сергеевич</b>
<b>ФИО руководителя:</b>	<b>Маргарянц Никита Борисович</b>

**Отчет на 18 листах**

**Подпись стажёра:**



# **ПРИМЕНЕНИЕ СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ ДЛЯ ОЦЕНКИ СОСТОЯНИЯ КАПИЛЛЯРОВ ПО ДАННЫМ ВИДЕОКАПИЛЛЯРОСКОПИИ В УСЛОВИЯХ ОГРАНИЧЕННОГО ОБЪЕМА ОБУЧАЮЩЕЙ ВЫБОРКИ**

## **АННОТАЦИЯ**

Видеокапилляроскопия является важным неинвазивным диагностическим методом, используемым для оценки состояния микроциркуляторного русла и диагностики сосудистых заболеваний. Однако рутинный анализ изображений капилляров требует значительного опыта специалиста, занимает длительное время и сопряжён с субъективностью интерпретации. В связи с этим важной задачей является разработка автоматизированных систем, способных объективно и быстро классифицировать капилляры по их внешним морфологическим признакам.

В данной работе исследуется применение глубоких сверточных нейронных сетей (CNN) для автоматической классификации изображений капилляров с целью выявления участков капиллярной сети с различными особенностями. Обучение модели проводилось в условиях недостаточного объема размеченных данных, что характерно для многих медицинских задач. Для повышения устойчивости и генерализации модели были применены методы аугментации данных, регуляризации и нормализации слоев. В результате экспериментов получена CNN-модель, достигшая точности классификации около 74% на тестовой выборке.

В статье подробно рассмотрены архитектура и методика обучения нейронной сети, проанализированы причины ограниченной точности и даны рекомендации по дальнейшему улучшению качества модели: использование более сложных CNN-архитектур, трансферного обучения и расширения объема данных. Полученные результаты демонстрируют потенциал глубокого обучения в автоматизации диагностики

микрососудистых патологий даже при ограниченном наборе обучающих примеров.

### **КЛЮЧЕВЫЕ СЛОВА**

Видеокапилляроскопия, глубокое обучение, сверточные нейронные сети, классификация изображений, автоматизированная диагностика, медицинская визуализация.

# **APPLICATION OF CONVOLUTIONAL NEURAL NETWORKS FOR ESTIMATION OF CAPILLARY STATUS FROM VIDEOCAPILLAROSCOPY DATA UNDER CONDITIONS OF LIMITED TRAINING SAMPLE SIZE**

## **ABSTRACT**

Videocapillaroscopy is an important non-invasive diagnostic method used to assess the state of the microcirculatory bed and diagnose vascular diseases. However, routine analysis of capillary images requires considerable experience of a specialist, takes a long time and is associated with subjectivity of interpretation. Therefore, an important task is the development of automated systems capable of objectively and quickly classifying capillaries based on their external morphological features.

This paper investigates the application of deep convolutional neural networks (CNNs) for automatic classification of capillary images to identify sections of the capillary network with different features. The model was trained under conditions of insufficient marked-up data, which is common in many medical tasks. Data augmentation, regularization and layer normalization techniques were applied to improve the stability and generalization of the model. As a result of the experiments, a CNN model was obtained that achieved a classification accuracy of about 74% on the test sample.

The paper details the architecture and training methodology of the neural network, analyzes the reasons for the limited accuracy and gives recommendations for further improvement of the model quality: using more sophisticated CNN architectures, transfer learning and data augmentation. The results demonstrate the potential of deep learning in automating the diagnosis of microvascular pathologies even with a limited set of training examples.

## **KEYWORDS**

Videocapillaroscopy, deep learning, convolutional neural networks, image classification, automated diagnosis, medical imaging.

## ВВЕДЕНИЕ

Видеокапилляроскопия является одним из важнейших современных методов неинвазивной диагностики, позволяющим оценивать состояние микроциркуляции и выявлять ранние патологические изменения в капиллярах, особенно в ногтевом ложе. Данная методика находит широкое применение при диагностике таких заболеваний, как системная склеродермия, синдром Рейно, диабетическая ангиопатия и другие сосудистые патологии [1]. Ранняя диагностика с помощью капилляроскопии позволяет своевременно выявить изменения в строении капилляров, что существенно улучшает прогноз и помогает скорректировать терапевтические меры на ранних стадиях заболевания.

Современные достижения в области информационных технологий, в частности, развитие методов глубокого обучения, открывают новые возможности для автоматизации анализа медицинских изображений. Использование сверточных нейронных сетей (CNN) в задачах компьютерного зрения уже доказало свою высокую эффективность в распознавании и классификации изображений, что позволяет значительно повысить объективность диагностики. В условиях растущей нагрузки на медицинских специалистов автоматизированные системы, способные проводить предварительный анализ изображений капилляров, могут стать незаменимым инструментом в клинической практике.

Целью данной работы является разработка простой модели, способной автоматически классифицировать изображения отдельных участков капиллярной сети на три категории: нездоровые капилляры, здоровые капилляры и нераспознанные участки. Такое разделение имеет огромное клиническое значение, поскольку оно не только способствует выявлению патологических изменений, но и помогает идентифицировать области, требующие дополнительного внимания. Для достижения этой цели

в исследовании были использованы современные методы предобработки данных, балансировки выборки с применением алгоритмов oversampling и аугментации данных, что позволило значительно увеличить объем обучающей выборки и повысить устойчивость модели к переобучению.

Особое внимание уделялось построению архитектуры сверточной нейронной сети, адаптированной для решения задачи классификации медицинских изображений. Модель включала несколько блоков сверточных слоев с последующей нормализацией и операцией пулинга, а также полносвязные слои с регуляризацией посредством dropout. Такой комплексный подход позволил добиться высокой точности классификации, что подтверждается полученными результатами при тестировании модели.

Таким образом, представленное исследование объединяет достижения современной медицины и искусственного интеллекта, предлагая эффективное решение для автоматизированной диагностики заболеваний, связанных с нарушениями микроциркуляции. Разработка подобной модели может стать важным шагом в создании систем поддержки принятия клинических решений, способствуя повышению качества медицинской помощи и снижению вероятности ошибок при интерпретации изображений капилляров.

## МАТЕРИАЛЫ И МЕТОДЫ

### *Набор данных*

В качестве данных для тренировки модели были предоставлены изображения капиллярной сети в количестве 17 штук. Данные были получены с помощью прототипа мобильной зондовой системы VCS на базе лапароскопа, предназначенной для визуализации капилляров в области предплечья [2]. Один из снимков представлен на рисунке 1.




Рисунок 1 – Изображение капиллярной сети из обучающей выборки

Далее обучающая выборка была разбита на отдельные сегменты, представляющие из себя изображения части капиллярной сети и целых капилляров. Таким путем был получен датасет из 3918 снимков фрагментов капиллярной сети, после чего произведена ручная разметка данных по



классам: здоровые капилляры, нездоровые и неидентифицированные участки, представляющие из себя либо изображения с дефектами, либо темный участки капиллярной сети. На рисунке 2 представлено несколько фрагментов сегментированного изображения капиллярной сети, представителей каждого из классов.




Рисунок 2 – Фрагменты сегментированного изображения капиллярной сети.

а) – класс 0, нездоровые капилляры; б) – класс 1, здоровые капилляры; в) – класс 2, неидентифицированные области.

Далее полученные изображения были разделены в следующем процентном соотношении: 70% - обучающие данные, 15% - валидационные данные и 15% - тестовые данные.

Поскольку в изначальном виде представлено больше изображений капиллярной сети здоровых людей, то при обучении может возникнуть переобучение нейросетевой модели, что может негативно повлиять на ее работу с тестовыми данными. Для устранения дисбаланса классов был использован метод *RandomOverSampler* из библиотеки *imblearn*. Этот алгоритм обеспечивает равномерное представление всех классов в обучающей выборке за счет искусственного увеличения числа образцов миноритарных классов, что является критически важным для стабильного

обучения модели. В результате количество изображений тренировочной выборки стало равным 7041, валидационной и тестовой по 588.

### *Методы*

Во время обучения модели перед подачей на её вход изображения производилась их нормализация, все значения пикселей изображений преобразовывались в диапазон от 0 до 1 путём деления на 255. Такой подход способствует ускорению сходимости модели и снижает вероятность возникновения числовых перепадов, что положительно сказывается на стабильности обучения. После чего производилась аугментация данных непосредственно в процессе обучения модели. Для реализации аугментации и нормализации использовался класс `ImageDataGenerator` включенный в API Keras библиотеки TensorFlow.

Для решения задачи классификации изображений капилляров была разработана сверточная нейронная сеть (CNN, convolutional neural network), построенная с использованием библиотеки TensorFlow и ее высокоуровневого API Keras [3].

Архитектура модели, представленная на рисунке 3, включает четыре последовательных сверточных блока и серию полносвязных слоев для финальной классификации. Каждый сверточный блок состоит из следующих компонентов:

- *Сверточный слой (Conv2D)* с фильтрами размером 3x3, который отвечает за извлечение пространственных признаков из изображений. В каждом последующем блоке количество фильтров увеличивается (32, 64, 128 и 256 соответственно), что позволяет модели изучать признаки на различных уровнях детализации [3].
- *Слой пакетной нормализации (BatchNormalization)*, ускоряющий обучение и стабилизирующий градиенты [4].

- *Слой подвыборки (MaxPooling2D) с размером окна 2x2, снижающий размерность извлеченных признаков и помогающий модели концентрироваться на наиболее значимых характеристиках [3].*

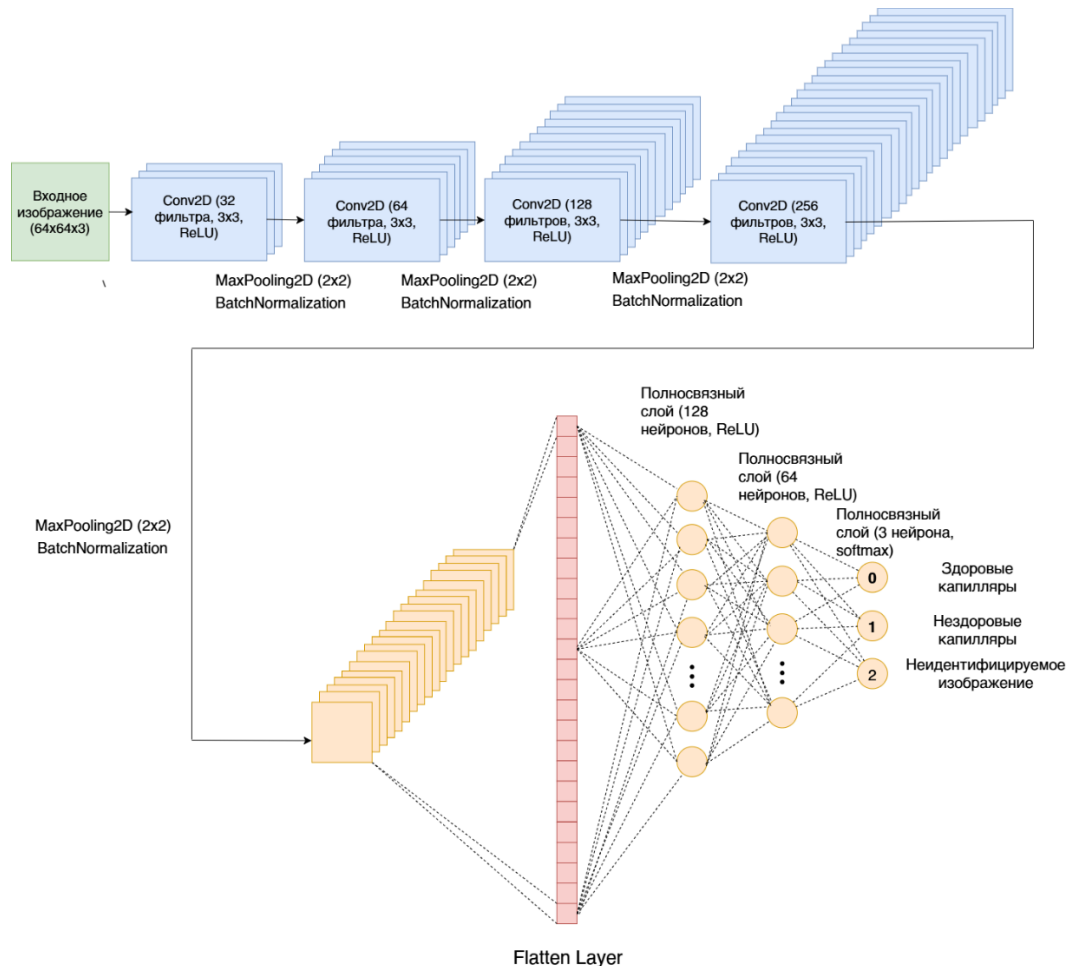


Рисунок 3 – Архитектура классификационной CNN-модели

После серии сверточных блоков используется слой выпрямления (Flatten), который преобразует многомерные карты признаков в одномерный вектор для передачи на вход полносвязным слоям [5].

Последовательность полносвязных слоев включает:

- *Полносвязный слой с 128 нейронами и функцией активации ReLU, сопровождаемый слоем Dropout с коэффициентом 0.5, что снижает вероятность переобучения.*

- *Второй полносвязный* слой с 64 нейронами и функцией активации ReLU, после которого также применён слой Dropout с коэффициентом 0.3.
- *Финальный выходной полносвязный слой* состоит из 3 нейронов (по числу классов) с функцией активации Softmax, позволяющей интерпретировать выходные значения как вероятности принадлежности изображения к одному из трех классов: «нездоровые», «здоровые» и «нераспознанные».

Предложенная архитектура CNN-модели обеспечивает высокую точность и надежность при классификации капилляроскопических изображений, а также демонстрирует устойчивость к вариативности входных данных благодаря применению техник нормализации и регуляризации.

## РЕЗУЛЬТАТЫ

Разработанная CNN-модель была обучена и протестирована на наборе капилляроскопических изображений, разделенных на три класса: «нездоровые», «здоровые» и «нераспознанные участки». После обучения модель показала точность классификации на тестовой выборке, равную 74%.

На основе анализа матрицы ошибок (confusion matrix), представленной на рисунке 4 установлено, что модель эффективно распознает классы «здоровые» и «нездоровые», однако допускает заметные ошибки при идентификации «нераспознанных участков», что обусловлено сложностью и неоднозначностью этой категории.




Рисунок 4 – Матрица ошибок

На графиках точности и потерь на обучении и валидации (рисунок 5) демонстрируется некоторая изменчивость, но при этом значения точности на валидационной выборке следуют общему тренду обучающей выборки.

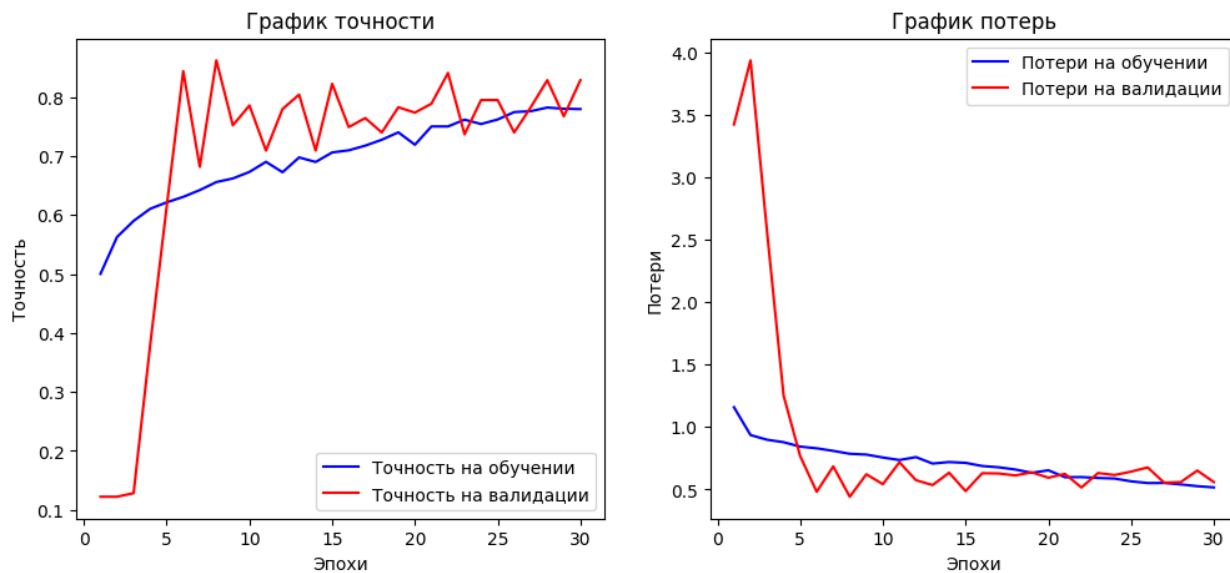


Рисунок 4 – Графики точности и потерь на обучении и валидации

## ОБСУЖДЕНИЕ

Полученные результаты указывают на хорошую работоспособность предложенной CNN-модели в решении задачи классификации капилляроскопических изображений. Несмотря на умеренную общую точность модели (74%), наиболее значимые классы («здоровые» и «нездоровые») распознаются достаточно стабильно. Отмеченные ошибки при классификации «нераспознанных участков» можно объяснить сложностью выделения четких признаков для данного класса, а также возможной субъективностью исходной разметки.

Графики обучения демонстрируют незначительные колебания значений точности, однако тренд на валидационной выборке стабильно следует за обучающей, что позволяет сделать вывод о том, что модель не страдает от переобучения, так как нет явного расхождения графиков точности обучения (резко вверх) и валидации (резко вниз). Скачки на валидационной выборке могут быть вызваны малым количеством обучающих данных, их сложностью, шумом или недостаточной регуляризацией, однако если при этом тренд валидации совпадает с трендом обучения, это указывает на достаточную обобщающую способность. Для дальнейшего улучшения качества классификации возможно увеличение объема и разнообразия тренировочных данных, а также дополнительная оптимизация архитектуры сети и подбор гиперпараметров.

Таким образом, несмотря на выявленные ограничения, разработанная модель представляет значительный потенциал для автоматизации процесса диагностики в капилляроскопии и может стать эффективным инструментом поддержки принятия врачебных решений. Например, возможно реализовать систему для выделения областей на снимке капиллярной сети, на которые стоит обратить внимание. Данная классификационная модель позволит выделять сегменты определенных классов, что впоследствии может

повлиять на диагностическое решение или поможет обратить внимание на те области, которые не были замечены специалистом. Пример работы такой системы представлен на рисунке 5, где выделенные голубым цветом области соответствуют изображениям, классифицируемым моделью как нездоровые капилляры (класс 0).




Рисунок 4 – Пример работы модели по классификации капилляров с выделением нездоровых участков на исходном изображении



## ЗАКЛЮЧЕНИЕ

Несмотря на неплохие представленные результаты классификационной модели использование ее на практике в данный момент является невозможным, так как ее точности недостаточно для решения медицинских задач. Необходимо произвести модернизацию модели в области архитектуры, реализовать трансферное обучение, для уменьшения вероятности ошибок и увеличения точности классификации, а также увеличить базу данных для возможности улучшения процесса обучения и устранения дисбаланса классов, который на данный момент представляет самую главную проблему, встречаемую на пути разработок моделей для создания систем поддержки принятия решений в области медицины.

**Источник финансирования.** Данная статья подготовлена и представлена автором в рамках стажировки в лаборатории «Технического зрения» университета ИТМО.

**Конфликт интересов.** Автор декларирует отсутствие явных и потенциальных конфликтов интересов, связанных с публикацией настоящей статьи.

**Благодарности.** Автор выражает благодарность Маргарянцу Н.Б. за предоставленные материалы и сотрудничество в рамках написания представленной статьи.

## ЛИТЕРАТУРА/REFERENCES

1. Isha Sood, Nikunj Kumar Dadhaniya, Sundeep Kumar Upadhyaya, Sirinder Jit Gupta, Rohini Handa. Nailfold capillaroscopy – An underutilized investigation in rheumatolog. Apollo Medicine. 2017; 17: 21-26. <http://doi.org/10.1016/j.apme.2017.01.003>
2. Volkov, M.V., Margaryants, N.B., Potemkin, A.V. et al. Blood Vessel Visualization Method in Human Skin Based on Video Recording of Blood Flow Using a Laparoscope. J. Commun. Technol. Electron. 65, 806–814 (2020). <https://doi.org/10.1134/S1064226920070141>
3. Багаев, И.И. Анализ понятий нейронная сеть и сверточная нейронная сеть, обучение сверточной нейросети при помощи модуля TensorFlow. Математическое и программное обеспечение систем в промышленной и социальной сферах. – 2020. – Т.8. – № 1. – С. 15-22. DOI: 10.18503/2306-2053-2020-8-1-15-22.
4. Keras 3 API documentation. Flatten layer Available at: [https://keras.io/api/layers/reshaping\\_layers/flatten/](https://keras.io/api/layers/reshaping_layers/flatten/). Accessed 27.03.2025.
5. Keras 3 API documentation. BatchNormalization layer Available at: [https://keras.io/api/layers/normalization\\_layers/batch\\_normalization/](https://keras.io/api/layers/normalization_layers/batch_normalization/). Accessed 27.03.2025.